



RÉPUBLIQUE DU BÉNIN
Université d'Abomey-Calavi (UAC)
Institut de Formation et de Recherche en Informatique (IFRI)

RAPPORT DE PROJET

Licence 3 – Intelligence Artificielle

Prédiction des pannes de machines pour la maintenance préventive

Présenté par :
Fedel FOLLY
Emmanuella GBODO
Généreux TCHIAKPE

Superviseur :
Ratheil HOUNDEJI

Année académique : 2025 – 2026

Table des matières

1	Introduction	2
2	Contexte et objectifs	2
3	Description des données	2
4	Prétraitement et ingénierie des variables	3
5	Modélisation	3
6	Évaluation des modèles	3
7	Validation du meilleur modèle	4
8	Mise en production : API FastAPI	5
9	Discussion	5
10	Conformité aux directives du hackathon (volet BMI)	6
11	Reproductibilité technique	6
12	Livrables complémentaires	7
13	Conclusion	7

1 Introduction

La maintenance prédictive consiste à anticiper les défaillances avant qu’elles ne provoquent un arrêt non planifié. Dans un contexte industriel, cet objectif est stratégique pour réduire les coûts de maintenance corrective, limiter les pertes de production et améliorer la disponibilité des équipements.

Dans ce projet, nous avons construit une chaîne complète : exploration des données, entraînement de plusieurs modèles supervisés, optimisation des seuils de décision, validation comparative, puis mise en production via une API *FastAPI* avec interface web de test.

2 Contexte et objectifs

Le problème étudié est une classification binaire : prédire la variable `failure_next_24h` (panne dans les 24h à venir). Les objectifs techniques étaient :

- gérer le déséquilibre de classes,
- maximiser le **F1-score** (compromis précision/rappel),
- comparer plusieurs approches de modélisation,
- sélectionner automatiquement le meilleur modèle,
- exposer un service de prédiction réutilisable.

3 Description des données

Le jeu de données principal contient **200 000 observations** et **15 colonnes**. Après vérification de la cible non nulle, la répartition observée est :

- classe 0 (pas de panne) : 164 204 observations,
- classe 1 (panne) : 35 796 observations,
- taux de panne global : 17.898%.

Les variables incluent notamment : `machine_type`, `maintenance_age_days`, des indicateurs vibratoires, thermiques, électriques et acoustiques.




FIGURE 1 – Distribution de la variable cible `failure_next_24h`.

4 Prétraitement et ingénierie des variables

Le pipeline expérimental utilise les étapes suivantes :

- suppression des lignes où la cible est absente,
- encodage de `machine_type` (ou traitement via pipeline),
- génération de variables temporelles lorsque `timestamp` est disponible (`hour`, `day_of_week`, `is_weekend`),
- séparation entraînement/test avec `train_test_split` stratifié,
- standardisation / transformations selon le modèle.

Les tailles utilisées dans les métadonnées validées sont :

- entraînement : 57 368,
- test : 40 000.

5 Modélisation

Trois familles de modèles ont été entraînées et comparées :

1. **LightGBM pipeline**,
2. **Logistic Regression équilibrée**,
3. **Random Forest SMOTE pipeline**.

Le protocole de comparaison repose sur un même jeu de test et une logique de seuil optimisé pour améliorer le F1-score.

6 Évaluation des modèles

La table ci-dessous synthétise les métriques *tuned* produites dans `models/model_validation_summary`

Modèle	Seuil	Precision	Recall	F1
LightGBM pipeline	0.5177	0.2791	0.7359	0.4047
Logistic Regression équilibrée	0.4750	0.2735	0.7215	0.3967
Random Forest SMOTE pipeline	0.5000	0.2718	0.5034	0.3530

TABLE 1 – Comparaison finale sur le jeu de test (métriques *tuned*).




FIGURE 2 – Comparaison visuelle des métriques *tuned* (F1, Recall, Precision).

Le meilleur modèle retenu est donc **LightGBM pipeline**, principalement pour son meilleur F1-score. Son seuil de décision retenu est **0.517718**.

7 Validation du meilleur modèle

La matrice de confusion du meilleur modèle (seuil optimisé) est :

$$\begin{bmatrix} 19236 & 13605 \\ 1891 & 5268 \end{bmatrix}$$




FIGURE 3 – Matrice de confusion du meilleur modèle validé.

Cette matrice confirme un rappel élevé sur la classe panne (objectif métier prioritaire), avec un compromis sur la précision lié au déséquilibre des classes.

8 Mise en production : API FastAPI

Une API de prédiction a été implémentée pour industrialiser l'usage du modèle.

Fonctionnalités principales

- chargement automatique du meilleur modèle via `model_validation_summary.csv`,
- endpoints `/health`, `/model-info`, `/predict`,
- validation des features attendues,
- interface HTML simple pour tester les prédictions,
- génération de données synthétiques depuis l'interface.

Extrait de logique de sélection automatique

Listing 1 – Sélection du meilleur modèle par F1 dans l'API

```
1 summary_df = pd.read_csv(SUMMARY_CSV)
2 summary_df["_f1_num"] = pd.to_numeric(summary_df["f1_tuned"], errors="
  coerce")
3 summary_df = summary_df.sort_values("_f1_num", ascending=False,
  na_position="last")
4 best_row = summary_df.iloc[0].to_dict()
5 model_file = best_row["model_file"]
```

9 Discussion

Forces

- approche bout-en-bout (de l'EDA à l'API),
- protocole de validation unifié,
- optimisation des seuils orientée métier,
- sélection automatique du meilleur modèle.

Limites

- performance contrainte par le déséquilibre de classes,
- précision encore modérée sur la classe positive,
- dépendance aux patterns du dataset disponible.

Pistes d'amélioration

- calibration probabiliste et coût asymétrique des erreurs,
- enrichissement des variables temporelles,
- validation croisée temporelle,
- suivi en production (drift, réentraînement périodique).

10 Conformité aux directives du hackathon (volet BMI)

Cette section synthétise la conformité du projet aux directives **pertinentes** pour le cas d'usage *maintenance industrielle prédictive BMI*.

Objectif principal

Le modèle final répond à l'objectif de prédiction de panne anticipée (horizon 24h) et a été sélectionné selon des métriques adaptées au déséquilibre des classes (Precision, Recall, F1, ROC-AUC, PR-AUC).

Méthodologie exigée

Les étapes demandées sont couvertes dans ce rapport :

- traitement/apurement des données,
- entraînement de plusieurs modèles,
- optimisation (notamment seuil de décision orienté F1),
- validation finale du meilleur modèle,
- prototypage d'une API de test et d'aide à la décision.

Confidentialité et usage des données

Les données du challenge ont été utilisées exclusivement pour ce projet académique de hackathon. Aucun partage externe non autorisé des données brutes n'est effectué dans les livrables produits.

Interprétabilité et explicabilité

L'interprétabilité est assurée à trois niveaux :

- **Variables d'entrée explicites** : `machine_type`, `maintenance_age_days`, indicateurs vibration/température/courant/acoustique et particules d'huile ;
- **Seuil de décision transparent** : le meilleur modèle est servi avec un seuil optimisé et exposé via l'API ;
- **Sorties lisibles pour décision** : matrice de confusion, rappel de la classe panne, comparaison multi-modèles.

Aide à la décision

Le prototype FastAPI (endpoints `/model-info` et `/predict`) fournit un support opérationnel pour tester des cas et orienter les interventions de maintenance préventive.

11 Reproductibilité technique

Les résultats sont reproductibles à partir des artefacts fournis dans le dépôt local :

- notebooks d'exploration et d'entraînement ;
- modèles sauvegardés dans `models/` ;
- script de génération des figures : `rapport/generate_figures.py` ;

— API de service : `api/main.py`.

Exécution minimale recommandée :

Listing 2 – Commandes de reproduction locale

```
1 pip install -r requirements.txt
2 python rapport/generate_figures.py
3 python -m uvicorn api.main:app --reload
```

12 Livrables complémentaires

En complément de ce rapport technique, les livrables attendus par le hackathon sont :

- code source versionné (GitHub/GitLab),
- démonstration vidéo du modèle final,
- support de présentation finale (pitch + démonstration).

Remarque : cette version du rapport se limite volontairement au périmètre maintenance industrielle BMI et exclut les éléments hors-sujet.

13 Conclusion

Ce projet démontre la faisabilité d'un système de maintenance prédictive orienté opérationnel. Le modèle LightGBM sélectionné obtient la meilleure performance globale selon le F1-score, tout en conservant un rappel élevé sur les cas de panne. L'API FastAPI et son interface web fournissent une base exploitable pour des tests métiers immédiats et une intégration future dans un environnement industriel.

Livrables techniques utilisés dans ce rapport :

- notebooks d'exploration, entraînement et validation,
- métadonnées modèles du dossier `models/`,
- API FastAPI implémentée,
- figures générées automatiquement dans `rapport/figures/`.